

# ELW의 BSM 이론가를 사용한 장단기 기억 순환 신경망 분류에 의한 헷징 전략과 투기 전략의 백 테스팅 성과 비교 보고서: 삼성전자 ELW를 중심 으로

KSIF DAR

기여자: Frank Chandler, 김 남일, 손 예준, 김 경준, 박 지선, 장 한이, 한 정현, 함 현중

## [요약]

ELW에 의한 전략은 크게 기초자산인 주식 가격의 변동을 헷지하는 용도나 그 변동의 방향 또는 규모를 미리 예측하고 투기적 전략을 취하는 두 종류로 나뉩니다. 이에 따라 본 보고서에서는 두 종류에 대한 신경망 학습을 통하여 백 테스팅을 수행하였습니다. 실증적 분석을 수행한 결과 일 주기 델타 헷지 전략은 하락하는 주가 경로에서 방어적인 기능을 해내었으며 투기적 전략은 옵션의 매도 포지션을 제외한 경우에서만 유의미한 수익을 보여주었습니다.

## 1. 서론

현재 파생상품 및 대체 투자(이하 DAR) 팀을 포함한 한국과학기술원 경영대학원 학생 투자 펀드의 구성원 중 일부는 옵션을 통한 투자 수행의 허용을 희망하고 있습니다. 이러한 요구의 근거는 단순히 옵션 가치의 큰 일 변동성에 기반한 투기적(speculative) 성격에 의한 것일 수도 있으나 가장 큰 이유는 팀원들이 경험한 covid19 사태의 높은 변동성을 헷징 하지 못한 기회 비용의 경험 때문입니다. 이에 본 보고서는 두 차례의 다른 성격의 전략을 장단기 기억 순환 신경망(LSTM)에 접목시켜 모의 투자(backtesting) 결과를 확인하고자 합니다.

본 보고서에 사용된 가정은 다음과 같습니다. ①ELW의 가격은  $t$  시점의 시가와 종가를 블랙-옵션 모형에 의해 산출한다. ②옵션의 역사적 변동성( $\sigma_H$ )은 과거 252거래일 간 자료를 이용하여 종가 시점에 슬라이딩 윈도우 방식으로 새로운 수익률을 포함하여  $\sigma_H$ 을 대체한다. ③만기시점까지의 기간( $\tau$ )은 알고리즘을 통해 만기시점으로부터 10 거래일(2주)이 남았을 때 월물의 변경(rolling)을 통해 매 시점 갱신한다. ④무위험 이자율은 테스트 기간 국채 3년물의 금리, 배당률은 해당 기간 삼성전자의 배당수익률을 사용한다. 즉 ELW의 이론적 가격은 BSM에서 도출하지만 다른 입력 변수들은 가능한 현실적인 가정을 도입하여 괴리를 낮추고자 하였으며  $\tau$ 는 실제 투자에서도 동일한 방식으로 통제 가능하기 때문에 본 보고서에서 차용한 이론적 옵션가격과 실제 옵션 가격 간의 차이는  $\sigma_H$ 와 실제 옵션의 내재 변동성에 의한 차이입니다. 과거 자료에서 발생하는 가격 차이는 실제 일별 행사가격 별 가격 변동을 사용하면 해결이 가능합니다. 그러나 현실적으로 10년이 넘는 기간에 대한 실제 옵션 데이터를 구축하는 것은 쉽지 않은 일이기 때문에 본 보고서에서는 앞서 정의한 옵션의 이론가를 사용하여 예측 및 투자 성과를 제시합니다.

## 2. 본론

### 2.1. 자료 설명

본 연구에서 사용하고자 하는 방법론은 장단기 기억 순환 신경망에 의한 분류 예측(classification)이며 이 예측의 목표(target)은 옵션의 합성 전략 중 어떠한 전략이  $t$  시점의 시가에 매수해서 종가에 매도할 때 가장 큰 수익을 줄 것인지를 맞추는 것입니다. 신경망 학습의 목표는 아래 표 2.1에서 나타난 전략들 중 하나를 골라서 시초에 포지션을 만들고, 종가에 이들을 모두 정리하는 것이며 손실 함수는 이들 중 가장 큰 수익을 주는 매매 방식을 고르도록 학습을 진행합니다. 옵션의 합성 전략은 다양하게 존재하지만 본 보고서에서는 KSIF의 특수한 구조를 고려하여 증거금과 위험 노출 정도를 최소화하는 전략들로만 구성하였습니다. 하지만 표 2.1의 long strangle과 short strangle은 앞의 두 전략(외가격 옵션에 의한 델타 헷징, 내가격 옵션에 의한 델타 헷징)에 비해 비교적 위험 성향이 강하기 때문에 이들을 제외한 학습과 포함한 학습을 따로 진행하였습니다. 이는 아무리 포지션을 구성하는 비용은 적게 들더라도 옵션의 변동성에 대한 투기는 앞의 델타 헷징 기반의 포지션과는 위험의 성격이 다르기 때문입니다. 마지막으로 본 연구에서는 주식의 가격  $S_0$ 에  $\pm 5\%$ 를 비율로 곱한 가격의 행사가격이 존재한다는 가정을 하고 있으므로 실제 투자에선 정확히 그 값이 아닌 가장 가까운 값을 대응해야 하는 현실의 시장과의 차이를 가지고 있습니다. 이는 앞서 설명하였듯 ELW의 행사가격 별 가격 변화 자료 구축 과정에서의 제한으로 인한 괴리입니다.

표 2.1

## 합성 전략 설명

전략	설명
OTM_put + Stock	시초의 델타 값만큼 외가격( $0.95 \cdot S_0$ ) 풋옵션 매수, 작은 하락 방지
ITM_put + Stock	시초의 델타 값만큼 내가격( $1.05 \cdot S_0$ ) 풋옵션 매수, 큰 하락까지 방지
Long Strangle	동일 수량 외가격( $0.95 \cdot S_0$ ) 풋, 외가격( $1.05 \cdot S_0$ ) 콜 매수
Short Strangle	동일 수량 외가격( $0.95 \cdot S_0$ ) 풋, 외가격( $1.05 \cdot S_0$ ) 콜 매도 <sup>1</sup>
Hold	시초에 주식 매수

표2.2

## 입력 변수명과 간략한 설명

변수	설명
S&P 지수	미국 대형주 반영, 차분값 및 범위값 사용
DOW 지수	미국 제조업 반영, 차분값 및 범위값 사용
NASDAQ 지수	미국 블루칩 반영, 차분값 및 범위값 사용
VIX 지수	VKOSPI 대응, 차분값 사용
Philadelphia 반도체 지수	미국 반도체 업종 반영, 차분값 및 범위값 사용
KOSPI	국내 증시 반영, 차분값 및 범위값 사용
삼성전자 가격	시계열 자료 성격 반영, 차분값 및 범위값 사용
삼성전자 거래량	삼성전자 관심도 반영, 차분값 및 범위값 사용
만기( $\tau$ )	옵션의 변동성 반영, 원계열 사용

<sup>1</sup> Short strangle은 옵션의 매도로 이루어졌지만 모든 옵션이 외가격으로 이루어졌기 때문에 작은 비용으로 만들 수 있다.

## 2.2 학습 방법 설명

본 연구에선  $t-1$  시점까지 슬라이딩 윈도우(sliding window)방식으로 훈련을 한 뒤  $t$  시점에 분류를 위한 LSTM의 예측에 따라 투자를 수행하는 방식을 취하고 있으며 이 방식은 그림 2.1에 나타나 있습니다.

그림 2.1

학습 및 예측 방법

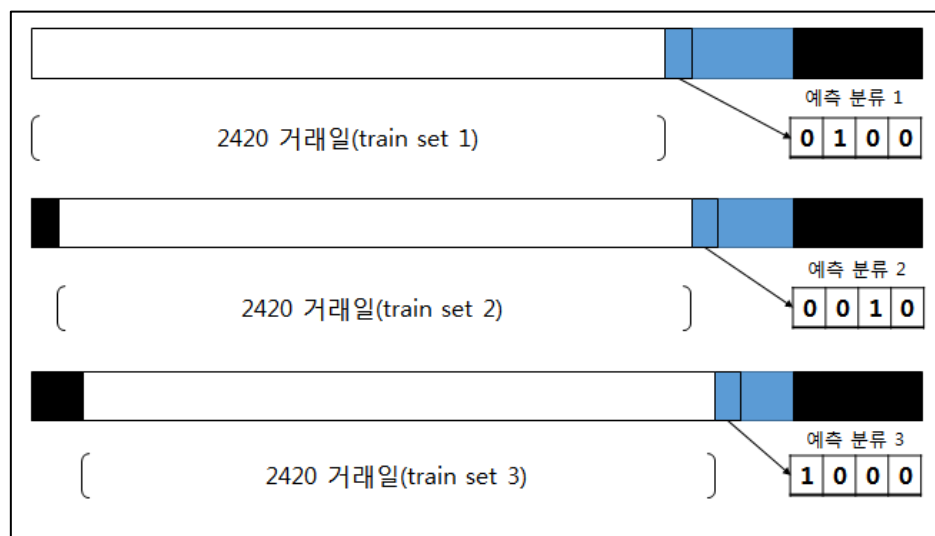


그림 2.1을 참고하면 본 보고서에서의 신경망 학습 방법은 다음의 예시와 같습니다. 먼저 2018.01.14~2018.03.27까지 2420 거래일을 첫 번째 학습 데이터로 사용하여 모수를 학습시키고 2018.03.28의 입력 변수를 통해 2018.03.28의 예측 분류를 수행 [ $f(X_{2421}|I_{1:2420})$ ]하고 그에 따른 투자 성과를 기록합니다. 이렇게 240 거래일을 슬라이딩 윈도우 방식으로 진행하여 2019.03.27까지 1년에 해당하는 총 240거래일(2018.05.02~2018.05.09까지 삼성전자 주식 분할로 인한 거래정지 이슈 존재)의 투자를 수행하여 그 성과를 기록합니다. 학습 성과를 나타내는 지표를 본 보고서에서는 정확도, 샤프 비율, F1 값을 사용합니다. F1 값을 사용하는 이유는 전체 데이터에서 short strangle에 대한 편향이 확인되었기 때문입니다. 이것이 의미하는 것은 일반적 상황에서 삼성전자가 일일 5%를 상회하는 변동성을 갖는 경우는 드물다는 것입니다. F1 값을 계산하는 과정은 아래 표 2.1과 2.2를 참고하면 실제로 short strangle을 해야 수익을 얻는 날 short strangle을 얼마나

해냈는지, 또는 short strangle을 예측했을 때 수익이 발생했는 지에 대한 조화 평균임을 알 수 있습니다. 조화평균의 특성 상 구성 성분 전체를 높여야 그 값이 같이 올라가는 성격이 있기 때문에 단순히 편향 된 자료에서 편향된 예측(모든 예측을 short strangle로 하는 경우)로는 높이기 힘들다는 의미가 그 구조에 있습니다.

학습에 사용한 모형은 장단기 기억 순환 신경망(LSTM)이며 그 구조는 그림 2.2에 자세히 나와 있습니다. 본 보고서에서 사용된 입력 변수의 경우 10 거래일을 기준으로 15개의 특성을 사용하였기 때문에  $(15 \times 15 + 15 \times 15 + 15 \times 1) \times 4 + 15 \times 3(4) + 15$ 에 의한 1920(1935)개의 모수가 두 종류(출력 변수에 hedge or hold만 사용하여 학습, speculative 집합을 추가하여 학습)의 모의 투자 성과 확인에 사용됩니다. 이 때 3개의 출력변수 노드가 사용되는 이유는 두 학습 모두 최종적으로는 3개의 결과만을 예측값으로 내놓았기 때문입니다. 따라서 240 거래일(2018.03.27~2019.03.27)에 대한 1900여 개의 매번 다른 모수가 두 종류의 서로 다른 패턴 집합을 사용하는 예측을 하고 있습니다.

표 2.1

성능 비교를 위한 예측 결과 분류

실제 분류	예측 분류	
	상승	하락
상승	실제 상승(TU)	거짓 하락(FD)
하락	거짓 상승(FU)	실제 하락(TD)

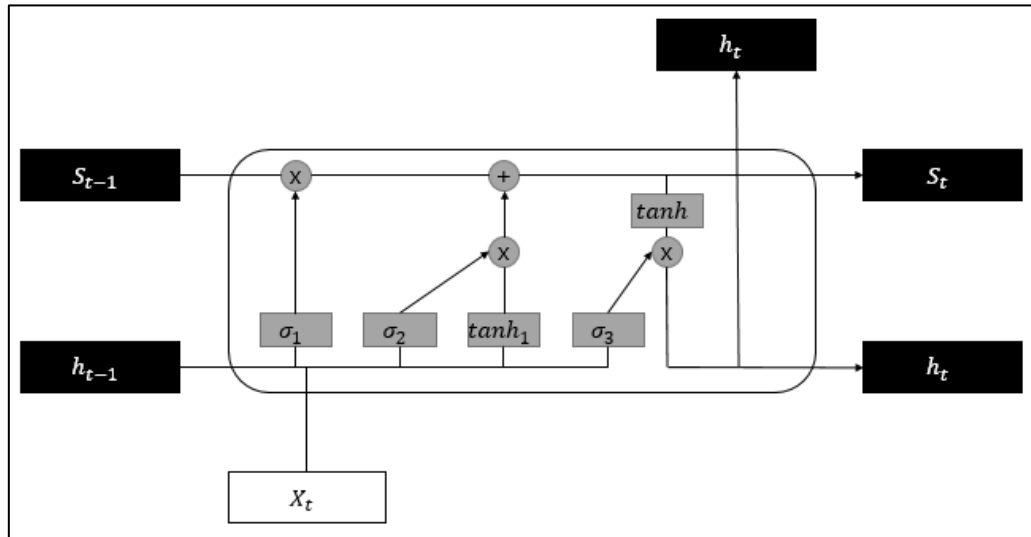
표 2.2

성능 비교를 위한 지표와 그 구조

지표	수식
정확도	$\frac{TU + TD}{TU + TD + FU + FD}$
정밀도	$\frac{TU}{TU + FU}$
재현율	$\frac{TU}{TU + FD}$
F1 값	$\frac{2}{\frac{1}{\text{정밀도}} + \frac{1}{\text{재현율}}}$

그림 2.2

장단기 기억 순환 신경망 구조도



## 2.3 실증 분석

본 보고서에서는 신경망 학습의 1회성 성과를 실제 투자에 적용하기에는 문제가 있을 것 (unrepeatable)이라 판단하여 시드를 바꿔보는 것으로 20회 정도의 동일 기간에 대한 분류 결과를 확인하였습니다(그 중 정확도 기준 평균적인 수준의 결과를 사용함). 일반적으로 블랙 박스의 문제를 해결하기 위해서는 부스팅, 랜덤 포레스트 기법 등을 통해 분류의 성능과 안정성을 높이지만 본 보고서에 사용된 입력 자료의 경우 시장의 구조가 변하면서 모수가 주는 비중도 변하는 경향이 강하게 나타나는 입력 변수들이 포함되어 있기 때문에 적용할 수 없었습니다. 예를 들어 VIX는 시장이 하락하는 환경에서는 모수에서 차지하는 비중이 크게 나타나지만 그렇지 않은 경우 오히려 다른 입력 변수들보다 비중이 낮게 나타났습니다. 이러한 경향은 옵션의 투기 전략이 포함 된 경우 더 크게 나타나는데, 만약 학습된 모수가 슬라이딩 윈도우 방식을 충분히 반영하지 않는다면(=시장의 구조 변화를 반영하지 못함) 옵션 매도 전략을 변동성이 크게 나타나는 구간에서 취하는 경우가 다수 발견되어 변동성이 급등하는 날 50%가 넘는 손해를 보는 경우도 종종 있었습니다. 분석에 사용한 기간 동안 삼성전자의 주가 경로는 그림 2.3과 같습니다. 주가 경로 상에는 초반부에 대세 하락이 있었으므로 헷지 전략의 목표는 이러한 하락을 얼마나 방어해내는 지를 확인하는 것이며 투기 전략의 목표는 이러한 하락에서 변동성에 대한 방향을 잘 맞추어 큰 수익을 낼 수 있는 지를 확인하는 것입니다. 그 결과는 아래에 모형 별로 제시하였습니다.

그림 2.3

테스트 기간 삼성전자 주가 경로





### 2.3.1 델타 헷지 전략(ITM put, OTM put, hold classification)

본 실험에서 사용된 포지션 구성 방식은  $t$  시점의 시가 기준 삼성전자 100주와 그 시점의 델타에 해당하는 분량( $\text{delta} \times 100$ 의 소수점 버림값)의 ①내가격 옵션 또는 ②외가격 옵션을 사거나 옵션 매수 없이 ③포지션을 유지하는 세 가지 중 하나를 고르는 것입니다. 분류는 앞서 설명한 장단기 기억 순환 신경망을 통해 예측된 분류를 고르는 것이며 그 투자 결과는 그림 2.4에 요약되어 있습니다. 또한 그 성능은 표 2.3에 나타나 있습니다. 240 거래일에 대하여 유의미한 수익률의 차이는 단측  $t$  통계량 기준 0.493( $p$  값:0.311)으로 관찰되지 않았으나 애초에 헷지 목적이었으므로 이러한 결과가 보편적인 현상입니다.

그림 2.4

삼성전자 헷지 모형과 buy&hold 모형 비교



표 2.3

## 벤치마크와 헷지 전략 성과 비교

	정확도	샤프 비율	F1 값(OTM에 대한)
벤치마크	NA	-0.211	NA
델타 헷지 전략	0.521	0.543	0.378

## 2.3.2 헷지 또는 투기전략1(헷지 전략 + long strangle + short strangle)

앞서 헷지 전략이 buy&hold 전략을 결과적으로 헷지의 목적을 달성하여 양호한 성과를 보여준 반면, 외가격 옵션을 매수할 지 매도할 지에 대한 판단까지 신경망에 학습시킨 투기전략1은 매번 동일한 이유로 심각한 손실을 보여주었습니다. 아래 그림 2.5의 경우도 단순 학습이 아니라 미리 labeling을 만기가 적게 남아있을 때에는 투기전략을 선택하지 말도록 지도를 해주었음에도 불구하고 모형은 short strangle에 편향적인 예측을 내놓았고 그 결과 기초 자산이 큰 폭으로 움직일 때마다 복구할 수 없는 손실을 확인할 수 있었습니다. 이는 표 2.4의 성능 비교를 통해 확인할 수 있습니다. 표 2.4를 보면 60%가 넘게 투기 전략에서의 정확도가 나타나고 있으며 F1 값도 꽤 높게 나타나고 있지만 실제로 확인된 short strangle로 인한 손실이 발생한 날이 72거래일로 전체 예측 실패 중 75% 이상을 차지하고 있으며 이는 short strangle에 대한 모형의 의존으로 인해 발생한 현상입니다. 이를 해결하기 위해선 손실함수의 구조를 조정하는 것이 필요하겠지만 본 보고서에서는 역량의 한계로 인하여 short strangle 포지션을 제외한 학습을 한 차례 다시 진행하였습니다. 이러한 우회 방식일 지라도 현재 KSIF는 옵션 매도 포지션을 만들기에는 장 중 관리가 어렵다는 점, 매도 포지션이 변동성에 의한 옵션 가격 변화에 더 크게 노출되어있다는 점을 고려하면 실효성이 있는 방법 중 하나입니다.

그림 2.5

삼성전자 투기 모형1과 buy&hold 모형 비교




표 2.4

벤치마크와 투기 모형1의 성과 비교

	정확도	샤프 비율	F1 값(Short_strangle에 대한)
벤치마크	NA	-0.211	NA
투기 전략1	0.62	-1.222	0.718

### 2.3.3 헷지 또는 투기 전략2(헷지 전략 + long strangle)

앞서 사용한 투기 전략 모형에서 short strangle에 대한 편향 된 예측에 의한 문제가 발견되었기 때문에 새로운 모형에서는 short strangle을 제거하였습니다. 그 결과 그림 2.6과 표 2.5에 나오는 것처럼 양호한 투자 성과를 확인할 수 있었으며 낮아진 정확도에 대해서는 더 이상 편향된 결과가 관측되지 않는 것으로 보상받을 수 있었습니다. 즉 모형은 헷징을 해야하는 날에는 헷징을 하고 있지만 높은 변동성이 기대되는 날에는 완벽하게는 아니더라도 높은 비율로 long strangle을

선택함으로써 높은 수익률을 보여주고 있습니다. 다만 이러한 날은 전체 거래일 중 3~4회에 한하였기 때문에 수익률 기준으로 확인한 t 통계량에선 여전히 단측 검정 시 t 통계량이 0.442(p 값:0.33)으로 일별 수익률까지 유의미한 초과 수익을 보여주고 있다고는 할 수 없었습니다. 따라서 투기 모형2가 비록 매도 포지션의 많은 양의 수익을 포기하더라도 헷지와 투자를 비편향적으로 분류해내었으므로 투기 전략 1보다는 우월한 전략이라고 볼 수 있습니다.

그림 2.6

삼성전자 투기 모형2과 buy&hold 모형 비교

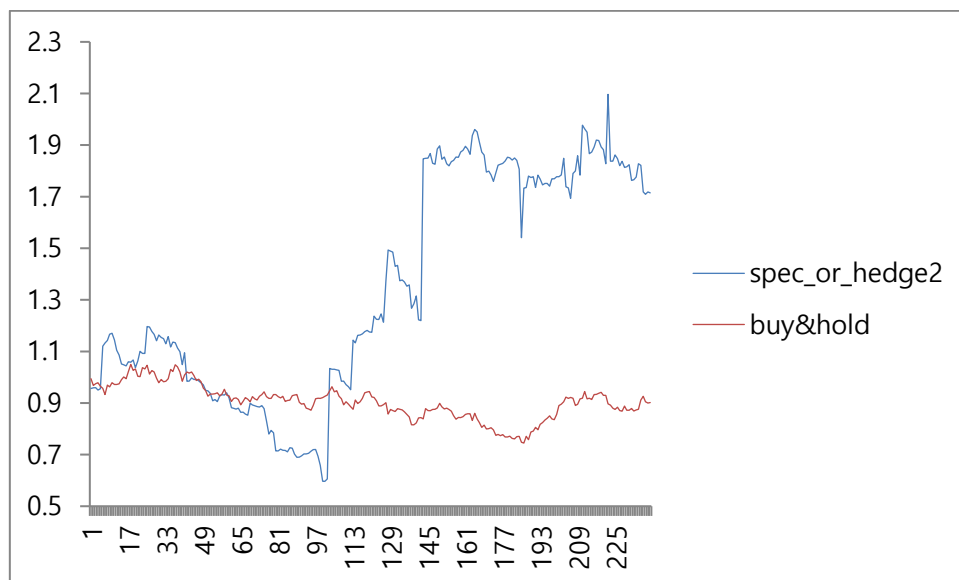


표 2.5

벤치마크와 투기 모형2의 성과 비교

	정확도	샤프 비율	F1 값(Short_strangle에 대한)
벤치마크	NA	-0.211	NA
투기 전략2	0.47	0.933	0.493

### 3. 결론

앞선 모형의 성과인 표 3.1의 결과 요약의 분석 통해 옵션 전략에 대한 분류 예측은 특기할 현상이 확인되었습니다. ①예측 모형은 short strangle이 존재할 때 헷지가 아닌 short strangle에 편향된 결과를 제시한다. ②이는 maximum 수익을 추구하는 labeling 방식이 헷지를 해도 양의 수익이 날 수 있었던 날에도 변동성이 약하다면 short strangle을 정답으로 채택하였기 때문이다. 본 연구에서는 이러한 현상을 극복하기보단 우회하는 방식을 선택하였으며 그 결과는 표 3.1에 나타난 바와 같이 최대 수익을 고르는 확률은 0.47으로 낮아졌을 지라도 편향된 선택을 하지 않았기 때문에 모형은 투기를 해야하는 날에는 투기성 판단을 하였고 그렇지 않은 날에는 헷징을 선택하는 방향으로 학습되었습니다. 만약 ①위험한 투자에 대한 비중을 제어하거나 ②일 중에도 투자에 대한 판단을 내리는 등 KSIF에서 시장 상황에 대해 더욱 효율적으로 대응할 수 있다면 선택의 제약의 문제에서 자유로워질 수 있을 것입니다. 따라서 본 연구에 대한 결론으로서 기초 자산에 대한 ELW는 ①일 주기로 시초와 종가에 거래가 가능하며 ②블랙 솔즈 모형의 이론가와 실제 가격의 괴리가 평균적으로 0에 수렴한다고 가정했을 때, 헷징 또는 옵션 매수에 의한 전략에서는 시장보다 양호한 샤프 비율을 기대할 수 있음을 실증적으로 확인하였습니다. 따라서 옵션의 가격 변화의 원리를 이해하고 있으며 신경망 모형의 적용이 가능한 경우에 한하여 KSIF의 ELW 투자 허용에 대한 긍정적인 실증 결과로서 본 보고서의 연구 결과를 제시합니다.

표 3.1

모형 별 결과 요약표

	정확도	샤프 비율	모형 별 F1 값
벤치마크	NA	-0.211	NA
델타 헷지 전략	0.521	0.543	0.378
투기 전략1	0.62	-1.222	0.718
투기 전략2	0.47	0.933	0.493